

基于深度展开(Deep Unfolding) 的无线通信算法研究

(省创结题答辩)

团队成员：付潇、张光义、张上展

指导教师：余官定教授

指导学长：胡棋昱博士

项目介绍

无线通信的困境

- 现有解决无线通信领域的算法大多是迭代的优化算法，虽然在收敛性和性能方面令人满意，但由于**极高的计算复杂度，难以商业应用**
- 5G 通信领域的**时间和空间复杂度挑战问题**仍待解决

项目目标

- 借鉴优化理论和深度学习，利用**既有迭代算法的特性**来设计深度展开的网络架构，在保证**性能损失在一定范围内**的前提下**极大降低计算复杂度**
- 为**5G时代高复杂度迭代算法的商用**提供帮助



Core: 深度展开 (Deep Unfolding)

解决通信问题
传统方法

Model-Based(白盒子)


优点：模型实用、准确性高

缺点：建模困难，尤其随着5G网络
复杂性增加，传统设计中用的
建模假设不再成立
(如干扰的不稳定和正太)

Machine-Learning(黑盒子)

优点：推理简单、架构通用

缺点：只考虑输入输出，泛化能力
和可解释性不好



Deep Unfolding(灰盒子)

白盒子和黑盒子的高效组合，
比白盒子的迭代次数少，
比黑盒子的学习参数少

具备较优收敛性和性能的同时上，
有一定可解释性

DLDUNN —— 数模混合预编码PDD算法

(1) 选择原因

- | | | |
|------------------------------|------|--|
| 1. 纯数字编码：应用落地 设备昂贵 | (泛化) | 1. 数模混合编码：落地 成本低 ，应用更广泛 |
| 2. WMMSE：仅为 单层 循环迭代网络 | ➡ | 2. PDD： 双层 循环迭代网络，仍未探索，通信领域的绝大部分算法循环不超过双层 |

(2) 背景: 混合预编码谱效率最大化 [3]

$$\begin{aligned} \max_{\mathbf{V}, \mathbf{U}} \sum_{k=1}^K \log \det \left(\mathbf{I} + \mathbf{U}_{RF_k}^H \mathbf{H}_k \mathbf{V}_{RF} \mathbf{V}_{BB_k} \mathbf{V}_{BB_k}^H \mathbf{V}_{RF}^H \mathbf{H}_k^H \mathbf{U}_{RF_k} \tilde{\mathbf{\Upsilon}}_k^{-1} \right) \\ s.t. \sum_{k=1}^K \|\mathbf{V}_{RF} \mathbf{V}_{BB_k}\|^2 \leq P \\ |\mathbf{V}_{RF}(i, j)| = 1, \forall i, j \\ |\mathbf{U}_{RF_k}(i, j)| = 1, \forall i, j, k \end{aligned}$$


➡ (功率及恒模约束)

$$\tilde{\mathbf{\Upsilon}}_k \triangleq \mathbf{U}_{RF_k}^H (\sigma^2 \mathbf{I} + \sum_{j \neq k} \mathbf{H}_j \mathbf{V}_{RF} \mathbf{V}_{BB_j} \mathbf{V}_{BB_j}^H \mathbf{V}_{RF}^H \mathbf{H}_j^H \mathbf{U}_{RF_k})$$

$\mathbf{V}_{BB}$ ：数字预编码器、 $\mathbf{V}_{RF}$ ：模拟预编码器

$\mathbf{U}_{BB}$ ：数字结合器、 $\mathbf{U}_{RF}$ ：模拟结合器

N_{RF} ：发送射频链、 M_{RF} ：接收射频链



物理流程图

[3] Shi Q, Hong M. Spectral efficiency optimization for millimeter wave multiuser MIMO systems[J]. *IEEE Journal of Selected Topics in Signal Processing*, 2018, 12(3): 455-468.

Algorithm 3 Penalty dual decomposition method

Input: Initialize $\mathbf{V}_{RF}$, $\mathbf{V}_{BB_k}$, $\mathbf{U}_{RF_k}$ and $\mathbf{X}_k$ to satisfy $\mathbf{X}_k = \mathbf{V}_{RF} \mathbf{V}_{BB_k}$, $|\mathbf{V}_{RF}(i, j)| = 1$, $|\mathbf{U}_{RF_k}(i, j)| = 1$, $\sum_{k=1}^K \|\mathbf{V}_{RF} \mathbf{V}_{BB_k}\|^2 \leq P$. Set the constraint violation parameter $\{\epsilon, \eta_0\}$, the penalty parameter ρ , the control parameter c .

Output: optimal $\{\mathbf{V}_{RF}, \mathbf{V}_{BB_k}, \mathbf{U}_{RF_k}, \mathbf{U}_{BB_k}\}$

```

1: repeat
2:   repeat
3:      $\mathbf{U}_{BB_k} = (\mathbf{U}_{RF_k}^H \mathbf{A}_k \mathbf{U}_{RF_k})^\dagger (\mathbf{U}_{RF_k}^H \mathbf{H}_k \mathbf{X}_k)$ 
4:      $\mathbf{W}_k = (\mathbf{I} - \mathbf{U}_{BB_k}^H (\mathbf{U}_{RF_k}^H \mathbf{H}_k \mathbf{X}_k))^{-1}$ 
5:      $\mathbf{V}_{RF} = \text{BCD} \left( \mathbf{I}, \mathbf{V}_{RF}, \sum_{k=1}^K \mathbf{V}_{BB_k} \mathbf{V}_{BB_k}^H, \right.$ 
         $\left. \sum_{k=1}^K (\mathbf{X}_k + \rho \mathbf{Y}_k) \mathbf{V}_{BB_k}^H \right)$ 
6:      $\mathbf{U}_{RF_k} = \text{BCD} \left( \mathbf{A}_k, \mathbf{U}_{RF_k}, \mathbf{U}_{BB_k} \mathbf{W}_k \mathbf{U}_{BB_k}^H, \right.$ 
         $\left. \mathbf{H}_k \mathbf{X}_k \mathbf{W}_k \mathbf{U}_{BB_k}^H \right)$ 
7:      $\mathbf{V}_{BB_k} = (\mathbf{V}_{RF})^\dagger (\mathbf{X}_k + \rho \mathbf{Y}_k)$ 
8:      $\mathbf{X}_k = (\mathbf{A}_\rho + \mu \mathbf{I})^{-1} \mathbf{B}_{\rho, k}$ 
9:   until  $\frac{|\mathcal{L}_k(\mathbf{x}^t) - \mathcal{L}_k(\mathbf{x}^{t-1})|}{|\mathcal{L}_k(\mathbf{x}^{t-1})|} \leq \epsilon$ 
10:  if  $\max_k \|\mathbf{X}_k - \mathbf{V}_{RF} \mathbf{V}_{BB_k}\|_\infty \leq \eta_t$  then
11:     $\mathbf{Y}_k = \mathbf{Y}_k + \frac{1}{\rho} (\mathbf{X}_k - \mathbf{V}_{RF} \mathbf{V}_{BB_k})$ 
12:  else
13:     $\rho = c\rho$ 
14:  end if  $t = t + 1$ 
15:   $\eta_t = 0.9 \max_k \|\mathbf{X}_k - \mathbf{V}_{RF} \mathbf{V}_{BB_k}\|_\infty$ ,  $\epsilon_k = c\epsilon_k$ 
16: until  $\max_k \|\mathbf{X}_k - \mathbf{V}_{RF} \mathbf{V}_{BB_k}\|_\infty \leq \epsilon$ 

```

应用凸优化的ADMM算法 → 将**非凸耦合的PDD问题**转换为左图双层算法迭代更新6个block，求解**全局最优解**

耦合约束： $\mathbf{X}_k = \mathbf{V}_{RF} \mathbf{V}_{BB_k}$

对偶变量： $\mathbf{Y}_k$

惩罚因子： ρ

$\mathbf{A}_k \triangleq \sigma^2 \mathbf{I} + \sum_{j=1}^K \mathbf{H}_k \mathbf{X}_j \mathbf{X}_j^H \mathbf{H}_k^H$
BCD-type algorithm can be found in [4]
$\mathbf{A}_\rho \triangleq \sum_{j=1}^K (\mathbf{H}_j^H \mathbf{U}_{RF_j} \mathbf{U}_{BB_j} \mathbf{W}_j \mathbf{U}_{BB_j}^H \mathbf{U}_{RF_j}^H \mathbf{H}_j) + \frac{1}{2\rho} \mathbf{I}$
$\mathbf{B}_{\rho, k} \triangleq \mathbf{H}_k^H \mathbf{U}_{RF_k} \mathbf{U}_{BB_k} \mathbf{W}_k + \frac{1}{2} \left(\frac{1}{\rho} \mathbf{V}_{RF_k} \mathbf{V}_{BB_k} - \mathbf{Y}_k \right)$
μ satisfies $\sum_{k=1}^K \text{Tr}(\mathbf{B}_{\rho, k}^H (\mathbf{A}_\rho + \mu \mathbf{I})^{-2} \mathbf{B}_{\rho, k}) = P$ and is obtained by applying bisection method.
$\mathcal{L}_k = \sum_{k=1}^K (\log \det(\mathbf{W}_k) - \text{Tr}(\mathbf{W}_k \mathbf{E}_k(\mathbf{U}, \mathbf{X})) + d) - \sum_{k=1}^K \frac{1}{2\rho} \ \mathbf{X}_k - \mathbf{V}_{RF} \mathbf{V}_{BB_k} + \rho \mathbf{Y}_k\ ^2$

支撑材料

我们的设计 : DLDUNN (Dual-layer deep-unfolding neural network) 网络




Fig. 1. The architecture of DLDUNN. The index $i, i + 1$ denote the current inner layer and the next inner layer, respectively. The index $t, t + 1$ denote the current outer layer and the next outer layer, respectively. The scale operation is placed after the final layer.

步骤(1): 固定DLDUNN内外两层的层数


步骤(2): 因**条件分支语句 (if-else)** 和**条件收敛语句**会造成反向传播的**梯度中断**。
故在每一内外层都对惩罚因子 ρ 和对偶因子 Y_k 保持更新，同时将BCD-type算法的迭代次数固定为1。

步骤(3): 为在每一层都保持合适的惩罚因子 ρ ，引入可训练的参数 c^* 取代原始固定的迭代标量： $\rho^{t+1} = c^* \rho^t$ 。

步骤(4): 引入可训练的矩阵参数 Z 和 O ，应对固定 $L_{BCD} = 1$ 的性能损失

$$\mathbf{V}_{BB_k}^{i+1} = \mathbf{Z}_k^i (\mathbf{V}_{RF}^i)^\dagger (\mathbf{X}_k^i + \rho^t \mathbf{Y}_k^t) + \mathbf{O}_k^{v,i}$$

步骤(5): 引入DNN网络取代二分法学习 μ^* 降低复杂度，同时引入 O 进行性能补偿



将信道 H 的实部、虚部展平输入DNN，
激活函数选取Sigmoid

步骤(6): 将二分法用DNN训的 μ^* 无法满足功率约束，仍然要加上Scale操作

$$\mathbf{V}_{BB_k} = \mathbf{V}_{BB_k}^* \frac{P}{\|\mathbf{V}_{RF} \mathbf{V}_{BB_k}^*\|^2}, \forall k$$

实验结果

(1) 参数设置：

复高斯信道参数： $h_{i,j} \sim \mathcal{CN}(0, 1)$

数据流： $d = 2$

接收天线数： M

发射天线数： N

发射射频链： $N_{RF} \geq Kd$


接收射频链： $M_{RF} = d$

DLDUNN内层网络数： $D_{in} = 10$

DLDUNN外层网络数： $D_{out} = 7$

谱效率取100次实验平均值

(2) 谱效率 (Spectrum Efficiency)



FD : (fully-digital)纯数字编码

RBD : 启发式算法 [4]


PSL : (PDD of same layer) 相同层数的PDD算法

# of user (K)	2	3	4	5
FD(bps/Hz)	28.985	40.964	51.880	62.038
PDD(bps/Hz)	28.932	40.801	51.643	61.513
Achievable performance (PDD-based)				
DLDUNN	97.82%	97.49%	97.57%	97.35%
PSL	77.91%	81.64%	86.77%	91.63%
RBD	75.88%	79.90%	83.86%	87.56%

② 不同用户数(K)的谱效率

① 不同SNR的谱效率, $K=3$, $d=2$, $N_{RF} = 12$

实验结果



分析:

- (1) FD结果(28.985bps/Hz)是上界, 因 $N_{RF} = N$
- (2) DLDUNN始终接近上界, 即使 $N_{RF} < 2Kd$
- (3) RBD启发式算法缓慢接近上界, N_{RF} 增加使得混合编码逐渐接近纯数字编码, 因而信道匹配策略更容易work

③ 不同射频链 N_{RF} 的谱效率, $K=2$, $SNR=20dB$ (成功的符号检测: $N_{RF} \geq Kd = 4$)

SNR/dB	12	14	16	18
DLDUNN	97.34%	97.77%	97.94%	97.78%
Black-box	84.50%	84.83%	87.23%	87.55%
SNR/dB	20	22	24	26
DLDUNN	97.84%	97.38%	97.62%	96.90%
Black-box	89.08%	89.02%	90.45%	90.64%

④ DLDUNN与黑箱的比较, $K=1$

实验结果

(3) 泛化性测试 (Generalization Analysis)

(3.1) DLDUNN用**较大的用户数K**训练好后，其网络参数可以直接应用于较小K的模型中

(3.2) DLDUNN用**20dB的SNR**训练好后，其网络参数可直接应用于不同SNR的场景下，性能结果如下表

SNR/dB	12	14	16	18
PDD (bps/Hz)	21.766	23.561	25.339	27.171
DLDUNN	97.41%	97.61%	97.43%	97.40%
SNR/dB	20	22	24	26
PDD (bps/Hz)	28.906	30.813	32.539	34.263
DLDUNN	97.82%	97.96%	97.77%	96.77%

⑤ 不同SNR的泛化谱效率

(4) 复杂度分析

(4.1) DLDUNN相比PDD迭代数更小，前者 $D_{in} \times D_{out}$ (70层) $\ll P_{in} \times P_{out}$ (通常大于10000次)

(4.2) DLDUNN和PDD优化内层所需的计算复杂度高。PDD通过BCD-type算法优化模拟预编码器 V_{RF} 和模拟结合器 U_{RF} 的复杂度分别为 $O(N^2 N_{RF}^2)$ 和 $O(KM^2 M_{RF}^2)$ ，然后DLDUNN中都只需要一层迭代。

(4.3) DLDUNN用矩阵相乘 $O(N^{2.37})$ 代替矩阵的伪逆 $O(N^3)$ ，当天线数增大后，复杂度降低明显

(4.4) DLDUNN不需要计算复杂度高的收敛变量 $L_k(x)$

主要贡献

(1) 提出了一种通用的**双层的**深度展开方法，其**降低复杂度和保持高性能**的思路适用于绝大部分高复杂度的通信算法(多为双层循环)。PDD算法的if-else分支、二分法、BCD-type算法代表了双层迭代算法的高度复杂情况，而DLDUNN对此已有很好的鲁棒性

Algorithm 1 : General dual-layer iterative algorithm

Input: Initialize $\mathbf{X} = \{\mathbf{X}_1, \mathbf{X}_2\}$
Output: Optimized variables $\mathbf{X}^* = \{\mathbf{X}_1^*, \mathbf{X}_2^*\}$

- 1: repeat
- 2: repeat
- 3: $\mathbf{X}_1 = F_i(\mathbf{X}_1; \mathbf{X}_2)$
- 4: until inner loop stopping criterion are met
- 5: $\mathbf{X}_2 = F_t(\mathbf{X}_2; \mathbf{X}_1)$
- 6: until outer loop stopping criterion are met
- 7: return $\mathbf{X}_1, \mathbf{X}_2$

双层迭代算法框架



Algorithm 2 : General dual-layer deep-unfolding framework

Input: Initialize $\mathbf{X} = \{\mathbf{X}_1^{0,0}, \mathbf{X}_2^0\}$
Output: Optimized $\mathbf{X}^* = \{\mathbf{X}_1^{T,I}, \mathbf{X}_2^T\}$

- 1: for t from 0 to $T - 1$
- 2: for i from 0 to $I - 1$
- 3: $\mathbf{X}_1^{t,i+1} = \mathcal{F}_i(\mathbf{X}_1^{t,i}, \mathbf{X}_2^t; \Theta^{t,i})$
- 4: end for
- 5: $\mathbf{X}_2^{t+1} = \mathcal{F}_t(\mathbf{X}_1^{t,I}, \mathbf{X}_2^t; \Theta^t)$
- 6: end for
- 7: return $\mathbf{X}_1^{T,I}, \mathbf{X}_2^T$

双层通用深度展开网络框架

(2) 由纯数字预编码过渡至混合预编码，适用于**更低成本、商业化的**5G/6G趋势